

Audion Voice AI

Audion Voice AI - Windows-first приложение для транскрибации файлов, live-диктовки, очистки текста и экспорта рабочих заметок. Проект собран вокруг двух сценариев: быстрый API workflow для повседневной работы и локальные GPU/CPU движки для автономной транскрибации больших записей.

Доустановка моделей распознавания

В раздачу не входят веса моделей — вместе они занимают около восьми гигабайт: кэш GigaAM, whisper.cpp с моделями large-v2 и large-v3-turbo, и pyannote для разделения по говорящим. У весов свои лицензии, отдельные от лицензии программы, а условия pyannote принимаются лично на HuggingFace — поэтому скачивает их сам пользователь, под своей учётной записью.

Пока модели не установлены, транскрибация не запустится: окно откроется, а распознавать будет нечем.

Запустите `builder_main.cmd` и выберите по очереди:

№	Пункт меню	Что ставит
08	<code>GIGAAM ONNX</code>	основная модель распознавания русской речи
09	<code>WHISPER.CPP CUBLAS</code>	движок whisper.cpp с ускорением CUDA
10	<code>WHISPER.CPP LARGE V2</code>	основная модель для файлов на русском
11	<code>CUDA / PYANNOTE</code>	разделение по говорящим — необязательно

Первые три шага обязательны. Одиннадцатый нужен только если вы размечаете диалоги по участникам; для него потребуется принять условия модели на HuggingFace.

FFmpeg и драйвер NVIDIA

Новее не значит лучше. Каждая сборка FFmpeg компилируется под конкретную версию заголовков NVENC, и каждая из них требует своего минимума драйвера. Поставьте самую свежую на драйвер постарше — аппаратное кодирование не ускорится, а перестанет работать.

Сборка FFmpeg	Заголовки NVENC	Минимальный драйвер NVIDIA (Windows)
9.0.1	ffnvcodec n13.1.15.0	610.0
8.0.1	ffnvcodec n13.0.19.0	570.0
7.1.1	ffnvcodec n13.0.19.0	570.0
7.1	ffnvcodec n12.2.72.0	551.76

Обратите внимание на третью строку: 7.1.1 собрана теми же заголовками, что и 8.0.1, и требует те же 570.0 — «откатиться на версию назад» на старом драйвере не даёт ничего. Помогает переход на 7.1 без патча.

Поэтому установщик подбирает сборку по вашему драйверу, а не берёт последнюю. Версии выше прочитаны из README самой сборки, пороги драйверов — из README nv-codec-headers.

Если видеокарты NVIDIA нет, всё это неважно: ставится последняя сборка, а кодирование идёт на процессоре.

Какая сборка идёт в поставке: 8.0.1. Это осознанный выбор, а не забытое обновление. Большинство машин для монтажа и кодирования сегодня живут на драйверах примерно с 571 по 609; ветка 610 стоит у считанных единиц. И 8.1.x, и 9.x требуют именно её — поставить их значит заявить аппаратное ускорение NVIDIA и не дать его большинству тех, кому оно обещано. В 8.0.1 есть всё, что используют эти программы, и она работает на тех драйверах, которые у людей действительно стоят.

Издания

Издание	Для чего	Движки
Audion Voice AI Live	Лёгкий дистрибутив для API Live и локальных моделей	OpenAI, xAI, ElevenLabs, GigaAM, whisper.cpp

Издание	Для чего	Движки
Audion Voice AI Studio	Расширенный дистрибутив для рабочих станций с CUDA	API providers, GigaAM, whisper.cpp, CUDA

Live остаётся основной версией для ноутбука и обычной работы. Studio добавляет CUDA/faster-whisper, PyTorch, GPU diarization и тяжёлые модели для машин с NVIDIA GPU.

Что умеет приложение

- Расшифровывает аудио и видеофайлы через OpenAI, локальные модели или CUDA faster-whisper в Studio.
- Ведёт очередь файлов и сохраняет результаты рядом с исходником по умолчанию.
- Поддерживает live-диктовку через API models (OpenAI, xAI, ElevenLabs) и Local Models (GigaAM, whisper.cpp).
- Показывает компактный overlay живой расшифровки поверх других окон.
- Делает очистку длинной live-диктовки через выбранную OpenAI-модель и настраиваемый prompt.
- Экспортирует результаты в Markdown, TXT, JSON, SRT и WebVTT.
- Отправляет материалы в Notion/Obsidian через GUI и tray-действия.
- Хранит тему, язык приложения, чекбоксы, заполненные поля, списки моделей и пользовательские настройки после перезапуска.
- Содержит вкладку установок для runtime, payloads, моделей и служебных проверок.

Интерфейс

GUI построен на PySide6. Основной layout разделён на рабочую область слева и настройки справа.

- **Live** - запуск диктовки, выбор API/Local источника, provider/mode, overlay и очистка live-текста.
- **Файлы** - очередь, движок транскрибации, язык записи, профиль OpenAI или локальная модель, постобработка/очистка, субтитры и экспорт.
- **Настройки** - тема, язык, tray-поведение, интеграции Notion/Obsidian и глобальные параметры приложения.

- **Установки** - рекомендуемый профиль установки, проверка модулей, установка runtime/payloads и прогресс установки. Reset App находится в **Настройках**.

Темы:

- **Mess Blue** - сине-графитовый HUD-стиль с голубыми акцентами.
- **Graphite Code** - графитовая тема с тёмно-оранжевыми акцентами.

Быстрый старт

1. Запустите **builder_main.cmd** для первичной сборки portable runtime или откройте уже собранное приложение.
2. В GUI используйте вкладку **Установки**: верхний блок показывает найденный GPU, рекомендуемый профиль и метки **Рекомендуется** / **По желанию** / **Не нужно**.
3. Проверьте API-ключи в **config\api_key_*.txt**, если используете OpenAI, xAI или ElevenLabs.
4. В **Установки** идите по логическому порядку: FFmpeg, Live dependencies, **Кэш зависимостей**, проверка микрофона, GigaAM ONNX, whisper.cpp, verify.
5. Проверка микрофона коротко открывает input-поток Audion и не сохраняет аудио.
6. Для Studio дополнительно установите faster-whisper, CUDA/pyannote и при необходимости Large models для сравнительных тестов.
7. Добавьте файлы в очередь, выберите движок и нажмите старт.

Строки с меткой **Не нужно** визуально приглушаются, но остаются доступными для ручного repair-сценария. Restore-пункты находятся внизу списка и нужны только для восстановления GigaAM provider после конфликтов пакетов.

Движки

API models

OpenAI Live не показывает каталог моделей: Realtime использует **gpt-realtime-whisper**, batch fallback использует **gpt-4o-mini-transcribe**. Для файлов OpenAI выбирается не raw model id, а профиль: **Быстро / экономно** (**gpt-4o-mini-transcribe**), **Макс. точность** (**gpt-4o-transcribe**) или **С диаризацией** (**gpt-4o-transcribe-diarize**). xAI и ElevenLabs подключены как фиксированные realtime Live-провайдеры.

Local Models

Локальный workflow выбирает между GigaAM и whisper.cpp. Для русского интерфейса GigaAM является предпочтительной локальной моделью; whisper.cpp остаётся CPU fallback в Live и CUDA/cuBLAS GPU pack в Studio. `GigaAM ONNX pack` ставит `onnx-asr`, ONNX Runtime provider и прогревает CTC/RNN-T payloads в `models\huggingface`; Windows auto выбирает DirectML как лёгкий универсальный backend, а в Studio на NVIDIA используется CUDA. GigaAM Live держит модель в памяти до полного выхода из приложения, чтобы не терять начало фразы.

В Studio кнопка `Транскрипция + диаризация` включает speaker labels для локальных файловых движков вторым проходом через `pyannote`. Для GigaAM файл автоматически режется на более короткие чанки (`diarization.gigaam_chunk_seconds`, по умолчанию 45 секунд), потому что GigaAM отдаёт chunk-level текст без word timestamps. Live-режим не использует pyannote, чтобы не добавлять задержки и тяжёлую CUDA-зависимость в диктовку.

Backend-пакеты ставятся так: `Кэш зависимостей` создаёт локальные wheels в `install\wheels`, а `GigaAM ONNX pack` ставит пакеты из этого кэша. Live создаёт `common`, `directml`, `cpu`; Studio дополнительно создаёт `cuda`. DirectML не требует внешнего SDK, CPU fallback идёт через `install\wheels\cpu`, CUDA используется только в Studio на NVIDIA после установки драйвера/runtime. TensorRT в проектном профиле не используется. Подробности есть в `USER_GUIDE_RU.md`.

CUDA

Доступен в Studio. Использует PyTorch/faster-whisper и NVIDIA CUDA для прогонов large-v2 и large-v3-turbo. В GUI карточка `CUDA` даёт профиль `Качество` / `Скорость`: `Качество` стоит по умолчанию и оставляет обычный Faster-Whisper/CTranslate2 ради более спокойной нагрузки, подробного таймлайна и лучшей пригодности для диаризации; `Скорость` включает batched inference (`batch_size=16`) для быстрых длинных прогонов с более высокой загрузкой GPU. В режиме `Транскрипция + диаризация` Studio может запускать `pyannote` после локальной транскрипции и назначать speaker labels по overlap таймлайна. Полные CUDA smoke-тесты выполняются на CUDA-машине.

Файлы и форматы

Очередь ориентирована на обычные аудио/видео форматы, которые надёжно принимает FFmpeg. Экзотические контейнеры лучше предварительно конвертировать. Результаты по умолчанию сохраняются рядом с исходником, чтобы не искать их в отдельной папке `output`.

Поддерживаемые экспортные форматы:

- Markdown
- TXT
- JSON
- SRT
- WebVTT

Live-диктовка

Live-режим может запускаться вместе с приложением, из GUI или из tray. Overlay показывает живые partials и не блокирует захват. Правый клик по нему открывает 20 последних завершённых диктовок, а tray - прокручиваемую историю до 200 записей с автоматическим удалением самых старых. Карточка повторно вставляет текст, круглые кнопки копируют или удаляют запись. Высота overlay регулируется во вкладке **Live**. Для длинных диктовок можно включить очистку: приложение накопит заданное количество предложений и отправит текст в выбранную модель очистки.

Tray

Tray используется для быстрых действий без открытия основного окна:

Сворачивание отправляет приложение в tray. Закрытие окна полностью завершает приложение и удаляет tray-иконку.

- старт и остановка live-диктовки;
- экспорт текущего лога в Markdown;
- экспорт материалов в Notion/Obsidian;
- доступ к основным действиям приложения.

Показ приложения в tray можно отключить в настройках.

Reset App

Кнопка **Reset App** восстанавливает дефолтные настройки UI и workflow. Она не должна удалять API-ключи, установленные runtime/payloads, скачанные модели и пользовательские рабочие файлы.

Cleanup и воспроизводимость

`cleanup_project.cmd` удаляет всё, что можно воспроизвести на другой системе: `runtime`, `Tools`, `models`, `install\download`, `install\wheels`, а также рабочие payload-папки вроде `input`, `output`, `logs`, `report`, `workspace`, `release`. Это намеренно: `input` является временной рабочей зоной, а не архивом пользователя.

Защищены `config`, `Docs`, `tests`, `system_core`, install-скрипты и корневые launch/build файлы. После cleanup пустая структура восстанавливается через `install\init_folders.cmd`.

Структура проекта

```
Audion Voice AI Live/  
  app/  
  config/  
  install/  
  system_core/  
  tools/  
  Docs/  
  builder_main.cmd  
  cleanup_project.cmd
```

Studio повторяет структуру Live и добавляет CUDA/PyTorch/faster-whisper payloads.

Документация

- `Docs/USER_GUIDE_RU.md` - подробное руководство пользователя.
- `Docs/USER_GUIDE_EN.md` - English user guide.
- `Docs/CODEX_CODE_CHANGES_2026-06-18.md` - журнал кодовых изменений.
- `Docs/CODEX_PRODUCT_EDITIONS_2026-06-18.md` - заметки по разделению Live/Studio.
- `Docs/CODEX_PLAN_LOCAL_STT_2026-06-18.md` - план локального STT.
- `Docs/CODEX_PLAN_HARDWARE_STT_EDITIONS_2026-06-18.md` - план аппаратных редакций.

Текущий статус

Live GUI, настройки, overlay, tray, API/Local переключатели и installer workflow приведены к рабочему состоянию. На RTX 5070 проверены целевые локальные профили: Live GigaAM

DirectML, Live whisper.cpp CPU fallback, Studio GigaAM CUDA и Studio whisper.cpp CUDA/cuBLAS.
GUI-каталог и `builder_main.cmd` синхронизированы; TensorRT исключён из пользовательского
профиля.